

현실에선 다 연결돼 있지만, 계산을 쉽게 하기 위해 "독립적"이라고 보는 것이다.

^^ 단어가 여러 개인 경우: 나이브 베이즈 계산법

* 문제 상황 : 어떤 이메일이 있어. 그 안에 다음과 같은 단어들이 있다고 해보자.

"무료", "쿠폰", "지금"

이 이메일이 스팸인지 아닌지(정상 메일인지) 판별하고 싶다.

* 확률 계산 구조

우리가 구하고 싶은 것은 $P(\text{스팸} \mid \text{무료, 쿠폰, 지금})$

즉, 이메일에 "무료", "쿠폰", "지금"이 있을 때, 이게 스팸일 확률은?

* 나이브한 가정: 단어들은 서로 독립이다.

나이브 베이즈는 이렇게 단순화해 준다.

$$P(\text{스팸} \mid \text{단어들}) \propto P(\text{스팸}) \cdot P(\text{무료} \mid \text{스팸}) \cdot P(\text{쿠폰} \mid \text{스팸}) \cdot P(\text{지금} \mid \text{스팸})$$

반대로 정상메일일 확률도 계산한다.

$$P(\text{정상} \mid \text{단어들}) \propto P(\text{정상}) \cdot P(\text{무료} \mid \text{정상}) \cdot P(\text{쿠폰} \mid \text{정상}) \cdot P(\text{지금} \mid \text{정상})$$

그리고 이 둘 중 더 높은 확률을 선택하면 된다.

간단한 예제로 계산해 보자.

1. 전체 이메일 통계

분류	이메일 수
----	-------

스팸	4
----	---

정상	6
----	---

총합	10
----	----

$$P(\text{스팸}) = 4/10 = 0.4, \quad P(\text{정상}) = 6/10 = 0.6$$

2. 단어 등장 확률 (스팸/정상 기준)

단어	$P(\text{단어} \mid \text{스팸})$	$P(\text{단어} \mid \text{정상})$		-----	-----	-----	무료	$3/4$	$1/6$		쿠폰	$2/4$	$1/6$		지금	$2/4$	$2/6$	
----	-------------------------------	-------------------------------	--	-------	-------	-------	----	-------	-------	--	----	-------	-------	--	----	-------	-------	--

3. 확률 계산

$$\text{스팸일 확률: } P(\text{스팸} \mid \text{단어들}) \propto 0.4 \cdot \frac{3}{4} \cdot \frac{2}{4} \cdot \frac{2}{4} = 0.4 \cdot 0.75 \cdot 0.5 \cdot 0.5 = 0.075$$

$$\text{정상일 확률: } P(\text{정상} \mid \text{단어들}) \propto 0.6 \cdot \frac{1}{6} \cdot \frac{1}{6} \cdot \frac{2}{6} = 0.6 \cdot 0.167 \cdot 0.167 \cdot 0.333 \approx 0.0056$$

스팸일 확률 ≈ 0.075 이고 정상일 확률 ≈ 0.0056 이므로

스팸일 확률이 훨씬 크니까 → 이 이메일은 스팸이라고 판단!

* 정리해 보면

- 나이브 베이즈는 단어별 확률을 곱해서 전체 확률을 구해 단어들이 서로 독립이라는 전제를 씀
- 각 클래스(스팸, 정상 등)에 대해 확률을 계산하고 가장 높은 쪽을 선택함