

폐암 환자 사망률

요인 분석 보고서

미니프로젝트1

- 참여자 :

권다솔, 김종성, 신중건, 장태영, 이충원, 전범하, 하태우, 김규택

1 서론

폐암은 전 세계적으로 높은 사망률을 보이는 주요 암종 중 하나로, 조기 진단과 치료가 생존율 향상에 핵심적이다.

본 프로젝트에서는 약 3,249,729건의 대규모 폐암 환자 데이터를 활용하여 생존율에 영향을 미치는 다양한 요인을 분석하고자 한다. 또한, 데이터를 기반으로 한 분석 결과를 시각화하고 웹페이지로 제작 및 배포까지 경험함으로써 실제 데이터 활용 프로세스를 종합적으로 이해하는 데 목적이 있다.

연구 목적

폐암 생존율에 영향을 미치는 주요 요인을 통계적 검정을 통해 규명하고, 다양한 데이터 시각화를 통해 요인 간 관계를 직관적으로 이해하며, 머신러닝 모델을 활용하여 환자의 생존 여부를 예측할 수 있는 가능성을 평가하는 것이다.

프로젝트 의의

본 프로젝트는 통계적 분석, EDA(Exploratory Data Analysis), 머신러닝, 웹 시각화와 WBS 활용을 통합한 종합 실습을 경험. 또한, 분석 결과를 웹페이지로 제작하고 배포하는 과정을 경험함으로써 실제 데이터 기반 의사결정 및 협업 과정 전반을 이해하고 실무 역량을 강화할 수 있다는 점에서 의미가 있다.

WBS, 데이터 출처 주소 및 웹사이트 배포 URL

WBS 주소

: [미니프로젝트1 WBS - Google Sheets](#)

데이터 출처

: [Lung Cancer Mortality Datasets v2](#)

2 데이터 개요

데이터 출처: Lung Cancer Mortality Datasets v2

샘플 수: 3,249,729명

특성 수: 17개

생존율: 22.0%

결측치: 없음

이상치 제거: 271개 샘플 제거, 전체 데이터의 0.0% 해당

데이터 구조 및 특징

1. 환자 정보에는 나이, 성별, BMI, 기존 질병, 흡연 상태, 음주 여부, 직업적 노출 여부, 가족력 등이 포함됨
 2. 치료 정보에는 치료 시작일, 종료일, 치료 유형(Chemotherapy, Radiation, Surgery, Combined)이 포함됨
 3. 질병 진행 단계 정보에는 병기(Stage I~IV), 진단 시 암 단계, 최초 치유 착수기간이 포함됨
- 지역 정보에는 유럽 내 지역(서유럽, 동유럽, 남유럽, 북유럽)이 포함됨

데이터 전처리 및 정제

결측치가 없고 이상치 제거도 최소 수준으로 데이터 신뢰성이 높음
범주형 변수는 연령대, BMI, 흡연/음주 상태, 병기 등 명확한 기준으로 그룹화
연속형 변수는 분석 편의성을 위해 필요 시 카테고리화하여 활용
위험 요인 점수 계산을 위해 흡연, 음주, 직업적 노출, 가족력 등 다중 요인을 통합 평가

데이터 활용 전략

연령대, 성별, 지역, 병기 등 범주형 변수는 카이제곱 검정을 통해 통계적 연관성 확인
BMI, 치료 기간, 최초 치유 착수기간 등 연속형 변수는 ANOVA 및 로지스틱 회귀 분석에 활용
위험 요인 점수 및 치료 지표를 종합하여 생존율에 미치는 영향 분석

3 변수 정의 및 전처리

3.1 연령대 분류

Young: 50세 미만

Middle: 5065세

Senior: 6580세

Elderly: 80세 이상

3.2 BMI 카테고리 분류

Underweight: $BMI < 18.5$

Normal: $18.5 \leq BMI < 24.9$

Overweight: $25 \leq BMI < 29.9$

Obesity: $BMI \geq 30$

3.3 위험 요인 점수 계산

흡연 상태: Never Smoked, Passive Smoker, Former Smoker, Current Smoker

알콜 소비: Never, Occasionally, Frequently

직업적 노출: Yes, No

가족력: Yes, No

3.4 치료 관련 지표

치료 기간: 치료 시작일부터 종료일까지의 일수

치료 유형: Chemotherapy, Radiation, Surgery, Combined

3.5 병기별 위험도 점수 생성

Stage I: 초기 단계

Stage II: 중기 단계

Stage III: 진행기 단계

Stage IV: 말기 단계


4 연구 가설 설정

4.1 나이가 어릴수록 폐암사망률이 높다

가설

H_0 : 나이가 어릴수록 사망률이 높다.

H_1 : 나이가 어릴수록 사망률이 높지 않다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 6.9508

p-value: 0.5419 > 0.05

정확도 (Accuracy): 0.7813

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결론: 나이 그룹과 사망 여부는 관련이 없다고 볼 수 있음.


<최종 결론>: 나이와 폐암 사망률 간에는 유의미한 연관성이 없다고 판단됨. ($p = 0.5419 > 0.05$) 머신러닝 평가 지표에서도 나이 그룹만으로는 사망 여부를 예측할 수 없는 수준임. 따라서, "나이가 어릴수록 폐암사망률이 높다"는 가설은 기각됨.

4.2 남성이 폐암사망률이 더 높다

가설

H_0 : 남성이 사망률이 더 높다.

H_1 : 남성이 사망률이 더 높지 않다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 0.0003

p-value: $0.9853 > 0.05$

정확도 (Accuracy): 0.7805

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수: 0.0

결론: 남성과 여성의 사망률 차이는 의미 없다고 볼 수 있음.


<최종 결론>: 통계적 검정과 머신러닝 평가 결과 모두 남성이 폐암 사망률이 높다는 가설을 지지하지 못함. 성별과 폐암 사망률 간에 유의미한 차이가 없음.

4.3 서유럽이 다른 지역에 비해 환자의 폐암사망률이 더 높다

가설

H₀: 서유럽 환자들이 북유럽, 동유럽, 남유럽 환자들보다 사망률이 더 높다.

H₁: 서유럽 환자들이 북유럽, 동유럽, 남유럽 환자들보다 사망률이 더 높지 않다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 22.1118

p-value: 0.6826 > 0.05

정확도 (Accuracy): 0.7805

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결론: 유럽 지역 그룹 간의 사망률 차이는 통계적으로 유의미하지 않음.


<최종 결론>: “서유럽이 폐암 사망률이 가장 높다”는 가설은 지지되지 않음.

4.4 천식 유무는 생존 여부에 영향을 미치지 않는다

가설

H₀: 천식 유무는 생존 여부에 영향을 미치지 않는다.

H₁: 천식 유무는 생존 여부에 영향을 미친다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 0.0001265715663595029

p-value: 0.9046525386670903 > 0.05

정확도 (Accuracy): 0.5175

정밀도 (Precision): 0.2196

재현율 (Recall): 0.4687

F1 점수: 0.2991


<최종 결론>: 천식 유무는 생존 여부에 영향을 미치지 않음.

4.5 콜레스테롤 수치는 폐암 사망률과 관련이 있다

가설

H₀: 콜레스테롤 수치가 높을수록 사망률이 높다

H₁: 콜레스테롤 수치가 높을수록 사망률이 높지 않다



분석(검정) 방법: 카이제곱

카이제곱 통계량: 3.92

p-value: 0.152 > 0.05

정확도 (Accuracy): 0.7803

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결과: 콜레스테롤 수치와 사망 여부는 관련이 없다고 볼 수 있음.

<최종 결론>: "콜레스테롤 수치가 높을수록 사망률이 높다"는 가설은 기각됨.

4.6 고혈압은 폐암 사망률과 관련이 있다

가설

H₀: 고혈압은 폐암 사망률과 관련이 있다

H₁: 고혈압은 폐암 사망률과 관련이 없다



분석(검정) 방법: 카이제곱

카이제곱 통계량: 3.92

p-value: 0.0477 < 0.05

정확도 (Accuracy): 0.7803

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결과: 고혈압은 폐암 사망률과 관련이 있음.


<최종 결론>: "고혈압이 있으면 사망률이 높다"는 가설은 지지됨.

4.7 BMI 수치는 폐암 사망률과 관련이 있다

가설

H₀: BMI와 사망률은 관련없다.

H₁: BMI와 사망률은 관련있다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 1.9348

p-value: 0.8581 > 0.05

정확도 (Accuracy): 0.7805

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결과: BMI와 생존 여부 사이에는 통계적으로 유의한 연관성이 없음.


<최종 결론>: "BMI가 높을수록 폐암 사망률이 높다"는 가설은 기각됨.

4.8 흡연 상태와 폐암 사망률

가설

H₀: 흡연 상태와 사망률은 관련없다.

H₁: 흡연 상태와 사망률은 관련있다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 0.5230

p-value: 0.9138 > 0.05

정확도 (Accuracy): 0.7805

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결과: 흡연 상태와 생존 여부 사이에는 통계적으로 유의한 연관성이 없음.


<최종 결론>: "흡연상태가 높을수록 폐암 사망률이 높다"는 가설은 기각됨.

4.9 간경변 유무는 생존 여부에 영향을 미치지 않는다

가설

H₀: 간경변 유무는 생존 여부에 영향을 미치지 않는다.

H₁: 간경변 유무는 생존 여부에 영향을 준다.



분석(검정) 방법: 카이제곱

카이제곱 통계량: 0.1507

p-value: 0.6979 > 0.05

정확도 (Accuracy): 0.6533

정밀도 (Precision): 0.2194

재현율 (Recall): 0.2264

F1 점수 (F1 Score): 0.2229


<최종 결론>: 간경변 유무는 생존 여부에 영향을 미치지 않음.

4.10 다른 암 보유 유무는 생존 여부에 영향을 미치지 않는다

가설

H₀: 다른 암 보유 유무는 생존 여부에 영향을 주지 않는다

H₁: 다른 암 보유 유무는 생존 여부에 영향을 준다



분석(검정) 방법: 카이제곱

카이제곱 통계량: 4.9445

p-value: 0.0262 < 0.05

정확도 (Accuracy): 0.6533

정밀도 (Precision): 0.2194

재현율 (Recall): 0.2264


F1 점수 (F1 Score): 0.2229

<최종 결론>: 다른 암 보유 유무는 생존 여부에 유의미한 영향을 미침.

4.11 기존 건강상태(폐암 외의 암, 고혈압)가 폐암 환자의 생존률에 영향 가설

H₀: 환자의 기존 건강상태(폐암 외의 암, 고혈압)는 폐암 생존률과 독립적이다.

H₁: 환자의 폐암 생존률은 기존 건강상태에 따라 달라진다.



분석(검정) 방법: ANOVA

F-statistic: 1.380

p-value: 0.491 > 0.05

정확도 (Accuracy): 0.7801

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결과: 고혈압과 폐암 외의 암 유무는 폐암 생존율에 관련이 없다.

p-value: other_cancer = 0.258 > 0.05,

hypertension = 0.086 > 0.05,

상호작용 = $0.491 > 0.05$

결론: 기저질환은 폐암 생존률에 영향을 끼치지 못함.


<최종 결론>: 폐암 환자가 기존에 앓고 있던 질병인 고혈압 폐암 외의 암은 폐암 생존율에 영향을 주지 못한다.

4.12 암 진단으로부터 최초 치유 착수기간이 짧을수록 환자의 생존율이 높다

가설

H₀: 최초 암 진단부터 치유기간과 암 단계는 생존률에 영향을 미친다.

H₁: 폐암 생존률은 최초 암 단계와 치유 착수기간에 달려있다.



분석(검정) 방법: ANOVA

F-statistic: 1.480

p-value: $0.515 < 0.05$

정확도 (Accuracy): 0.7801

정밀도 (Precision): 0.0

재현율 (Recall): 0.0

F1 점수 (F1 Score): 0.0

결과: 치유 착수기간과 암 단계는 폐암 생존율에 관련이 없다.

p-value: initiate_treatment_days = 0.208 > 0.05,

cancer_stage = 0.943 > 0.05,

상호작용 = 0.515 > 0.05

결론: 치유 착수기간과 암 단계는 폐암 생존률에 영향을 미치지 않음.

<최종 결론>: 대립가설 기각, 생존율과 치유착수기간 및 암 단계는 상관관계 없음.

5 Django 기반 웹 프로젝트

5.1 Django 파일 구조 및 기능 설명

팀에서 작성한 Django 웹 애플리케이션으로 프로젝트 분석 결과를 웹에서 확인할 수 있음

views.py에서 각 팀별 페이지(sol, jong, tack, final)로 데이터를 분류 및 전달

- dashboard 함수: 팀별 카드 내용과 종합결과 시각화 이미지 제공
- sol, jong, tack, final 함수: 각 팀의 가설 데이터와 이미지 제공
- get_hypothesis_data 함수: 페이지별 가설 데이터 호출

urls.py에서 path 설정으로 각 페이지 URL과 views 함수 연결

- 기본 경로("/"): dashboard
- "sol/", "jong/", "tack/", "final/": 각 팀 페이지 연결

settings.py에서 STATIC_URL과 STATICFILES_DIRS 설정으로 이미지 및 정적 파일 관리

load_images_from_static 함수로 static 경로에서 이미지 자동 로드

가설 데이터는 딕셔너리 구조로 관리되며, 각 페이지에서 필요한 이미지와 결과를 context에 전달하여 HTML에 렌더링

5.2 배포 URL

웹 애플리케이션을 배포한 주소를 입력하여 브라우저에서 결과를 바로 확인 가능

배포 URL : 여기에 유알엘 입력

6 분석 방법론

병기별 생존율 분석: 각 병기별로 생존율을 계산하고 비교하였다.

치료법별 생존율 분석: 각 치료법별로 생존율을 계산하고 비교하였다.

흡연 상태별 생존율 분석: 흡연 상태에 따른 생존율을 계산하고 비교하였다.

연령대별 생존율 분석: 연령대에 따른 생존율을 계산하고 비교하였다.

7 분석 결과

7.1 병기별 생존율 분석

Stage I / 22.0%

Stage II / 21.9%

Stage III / 22.0%

Stage IV / 22.0%

결론: 병기별 생존율에 유의미한 차이가 없었다.

7.2 치료법별 생존율 분석

Chemotherapy / 22.0%

Radiation / 22.0%

Surgery / 22.0%

Combined / 22.0%

결론: 치료법별 생존율에 유의미한 차이가 없었다.

7.3 흡연 상태별 생존율 분석

Never Smoked / 21.9%

Passive Smoker / 22.0%

Former Smoker / 22.0%

Current Smoker / 22.0%

결론: 흡연 상태와 생존율 간에 유의미한 관계가 없었다.

7.4 연령대별 생존율 분석

Young / 21.9%

Middle / 22.0%

Senior / 22.0%

Elderly / 22.3%

결론: 연령대와 생존율 간에 유의미한 상관관계가 없었다.

8 머신러닝 모델링

모델: 로지스틱 회귀

정확도: 78.04%

AUC Score: 0.5002

교차검증 AUC: 0.5013 (± 0.0005)

결론: 머신러닝 모델을 통해 생존 여부 예측이 가능함을 확인하였다.

9 결론 및 제언

병기, 치료법, 흡연 상태는 생존율에 유의미한 영향을 미치지 않았다.

연령대는 생존율에 유의미한 영향을 미치는 요인으로 확인되었다.

향후 연구에서는 연령대 외의 다른 요인들을 고려한 추가 분석이 필요하다.

10 참고자료

Kaggle. (2025). Lung Cancer Mortality Datasets v2. from

<https://www.kaggle.com/datasets/masterdatasan/lung-cancer-mortality-datasets-v2>

11 주간 회의 증빙 - 이미지 첨부 및 회의록 첨부

회의록 - Google Docs

8/29 - 주제 선정



9/1 - EDA 진행 회의(EDA 작업 착수)

9/2 - EDA 진행 회의(EDA 보완 및 재작업)

9/3 - 데이터 전처리, 가설 검정, 모델링 및 시각화

9/4 - 발표자료 제작, 보고서 작성, 웹 페이지 제작 및 배포

9/5 - 발표자료 전 최종점검, 최종발표

